

面向时变优化的高效预测-校正算法研究

林仲豪 (Lin Zhonghao)


北京理工大学自动化学院

2026 年 9 月 5 日



时变优化问题

时变优化面向**目标函数**和**约束条件**随时间变化的动态系统，目标是在数据持续流入时实时跟踪最优解轨迹。



核心特点

- ① 传统优化算法（如梯度下降）通常无法实时高精度追踪最优解
- ② 计算资源有限，任务实时性高
- ③ 最优解随时间的变化趋势可预测，需要设计合适的预测器。




离散时变优化

离散时变优化 (数值计算视角¹): 采样时刻 $t_k = kh$, 采样周期 $0 < h \ll 1$, 得到离散问题:

$$x_k^* := x^*(t_k) = \arg \min_{x \in \Omega_k} f_k(x, t_k),$$

数值算法在每个采样周期内迭代**有限步**, 生成序列 $\{x_k\}$ 近似最优序列 $\{x_k^*\}$ 。



- 渐进跟踪误差 (asymptotic tracking error, ATE): $\text{ATE} := \limsup_{k \rightarrow \infty} \|x_k - x_k^*\|$.
- 误差阶 (即跟踪精度), ATE 随 h 的标度, 如 $\text{ATE} = \mathcal{O}(h)$ 、 $\mathcal{O}(h^2)$ 等, 反映了算法**补偿时间变化**的能力。

¹Simonetto A, et al. Time-Varying Convex Optimization: Time-Structured Algorithms and Applications[J]. *Proceedings of the IEEE*, 2020, 108(11): 2032-2048.



现有工作：预测—校正框架

时变优化中，最优解轨迹本身随时间持续移动。若每个采样时刻仅执行“就地优化”，算法序列通常会相对于最优轨迹产生滞后。在离散时变优化中，跟踪精度一般不超过 $\mathcal{O}(h)$ 。

因此，问题应运而生：

如何达到 $\mathcal{O}(h^2)$ 以及更高阶的跟踪精度？

一种解决方案是，采用**预测—校正**框架²：

预测—校正框架

- 预测阶段：利用**模型信息**（如目标函数自身的二阶信息）或**历史轨迹信息**（即算法过去迭代值），估测最优解的前向变化趋势。预测器的“设计质量”直接决定了算法的跟踪精度；
- 校正阶段：在当前时刻利用优化流或优化算法进行有限步校正，降低预测残差，增强算法收敛性。

²Simonetto A, et al. A Class of Prediction-Correction Methods for Time-Varying Convex Optimization[J]. *IEEE Transactions on Signal Processing*, 2016, 64(17): 4576-4591.

现有工作：经典预测—校正算法共性特点

连续无约束时变优化预测—校正流³：

$$\dot{x}(t) = \boxed{-\nabla_{xx}^{-1} f(x, t)} \left[\underbrace{\nabla_{xt} f(x, t)}_{\text{预测}} + \underbrace{\kappa \nabla_x f(x, t)}_{\text{校正}} \right].$$

离散时变优化预测—校正算法：

预测： $x_{k+1|k} = x_k - h \boxed{\nabla_{xx}^{-1} f(x_k, t_k)} \nabla_{xt} f(x_k, t_k),$

校正（无约束）： $x_{k+1} = x_{k+1|k} - \gamma \nabla_x f(x_{k+1|k}, t_{k+1}),$

校正（有约束）： $x_{k+1} = \mathbb{P}_{\Omega_{k+1}} [x_{k+1|k} - \gamma \nabla_x f(x_{k+1|k}, t_{k+1})].$

总结：

- 现有预测—校正算法能取得较高跟踪精度，离散时变优化中可达 $\mathcal{O}(h^2)$ ；
- 强依赖二阶信息（如 ∇_{xx}^{-1} ）和时间信息，计算代价高，数值不稳定。



³Fazlyab M, et al. Prediction-Correction Interior-Point Method for Time-Varying Convex Optimization[J]. *IEEE Transactions on Automatic Control*, 2018, 63(7):1973-1986



设计目标

构建一类高跟踪精度、且无需 Hessian 求逆的预测-校正方法族，同时兼顾精度和计算代价。

① 连续无约束时变优化的 Hessian-inverse-free 预测-校正流

Lin Z, Hou J, and Zeng X. Hessian-Inverse-Free Prediction-Correction Method for Time-Varying Convex Optimization, *IEEE Conference on Decision and Control (CDC)*.

② 离散无约束时变优化的稀疏外推预测-校正算法

Lin Z, Hou J, and Zeng X. Optimal Prediction-Correction Algorithm Using Sparse Linear Extrapolation for Time-Varying Optimization, *IEEE Transactions on Signal Processing (TSP)*.

③ 带约束时变优化的原始-对偶预测-校正算法

Lin Z, Zeng X, Hou J, Sun J, Chen J. Primal-Dual Prediction-Correction Method with Tunable Memory for Linearly Constrained Time-Varying Convex Optimization, *Journal of Systems Science & Complexity (JSSC)*.

离散无约束时变优化的稀疏外推预测-校正算法

传统预测器结构举例：

$$x_{k+1|k} = \begin{cases} x_k \\ x_k - h \nabla_{xx}^{-1} f(x_k, t_k) \nabla_{xt} f(x_k, t_k) \\ x_k - h \frac{\|\nabla_t f(x_k, t_k)\| \nabla_x f(x_k, t_k)}{\|\nabla_x f(x_k, t_k)\|^2} \end{cases}$$


本课题：线性外推预测器

$$x_{k+1|k} = \sum_{i=0}^{r-1} a_i x_{k-i},$$

τ 步梯度下降校正：

$$\hat{x}_{k+1}^{(s+1)} = \hat{x}_{k+1}^{(s)} - \gamma \nabla_x f(\hat{x}_{k+1}^{(s)}, t_{k+1})$$

其中， $\hat{x}_{k+1}^{(0)} = x_{k+1|k}$ ， $x_{k+1} = \hat{x}_{k+1}^{(\tau)}$




分析难点：如何设计高预测精度的外推系数

$$a = [a_0, \dots, a_{r-1}]^T ?$$

如何设计高预测精度的外推系数?

重要观察

若 $x^*(t)$ 局部可由次数不超过 $n-1$ 的多项式精确表示, 则可用过去 r 个采样点 ($r \geq n$) 精确外推下一采样点。



n 阶轨迹正则性假设

最优轨迹 $x^*(t)$ 是 $(n-1)$ 次连续可微的, 且存在 $L_n > 0$, 使得 $\|x^{*(n)}(t)\| \leq L_n, \forall t \geq 0$ 。

更一般地, 若 $x^*(t)$ 具有 n 阶轨迹正则性, 则希望设计 $\mathbf{a} = [a_0, \dots, a_{r-1}]^T$, 使得

$$\left\| x^*(t_{k+1}) - \sum_{i=0}^{r-1} a_i x^*(t_{k-i}) \right\| = \mathcal{O}(h^n).$$

上式为局部截断误差, 衡量了预测器的预测精度。

关键假设: n 阶轨迹正则性是线性外推预测器达到 $\mathcal{O}(h^n)$ 精度的理论分析基础。



泰勒矩条件——高阶外推精度的充分条件

线性外推预测器:

$$x_{k+1|k} = \sum_{i=0}^{r-1} a_i x_{k-i}, \quad \mathbf{a} = [a_0, \dots, a_{r-1}]^\top.$$

引理：高阶预测精度

若 $x^*(t)$ 满足 n 阶轨迹正则性, 且 $\mathbf{a}$ 满足 n 阶泰勒矩条件, 则

$$\left\| x^*(t_{k+1}) - \sum_{i=0}^{r-1} a_i x^*(t_{k-i}) \right\| = \mathcal{O}(h^n).$$

进一步, 结合线性外推预测器形式, 可得

$$\left\| x_{k+1|k} - x^*(t_{k+1}) - \sum_{i=0}^{r-1} a_i (x_{k-i} - x^*(t_{k-i})) \right\| = \mathcal{O}(h^n).$$

n 阶泰勒矩条件 (充分条件)

$$\sum_{i=0}^{r-1} (i+1)^j a_i = \begin{cases} 1, & j = 0, \\ 0, & j = 1, \dots, n-1. \end{cases}$$

基于二项式系数的特例 (SHARP):

$$a_i = (-1)^i \binom{n}{i+1}, \quad i = 0, 1, \dots, n-1.$$

问: 满足 n 阶泰勒矩条件的外推系数 $\mathbf{a}$ 是否唯一? 答: $r = n$, 唯一 (即上面特例); $r > n$, 无穷组。



收敛性条件

将线性外推预测器的输出 $x_{k+1|k}$ 作为校正环节输入，进行 τ 步梯度下降校正：

$$\hat{x}_{k+1}^{(0)} = x_{k+1|k} \xrightarrow{\text{输入}} \boxed{\hat{x}_{k+1}^{(s+1)} = \hat{x}_{k+1}^{(s)} - \gamma \nabla_x f(\hat{x}_{k+1}^{(s)}, t_{k+1})} \xrightarrow{\text{输出}} x_{k+1} = \hat{x}_{k+1}^{(\tau)}$$

在一致 m -强凸性与 L -光滑性假设下， τ 步校正后，

$$\|x_{k+1} - x_{k+1}^*\| \leq \rho^\tau \|x_{k+1|k} - x_{k+1}^*\|,$$

其中 $\rho = \max\{|1 - \gamma m|, |1 - \gamma L|\} < 1$ 。

一致 m -强凸性与 L -光滑性假设

存在常数 $0 < m \leq L$ ，使得

$$mI \preceq \nabla_{xx} f(x, t) \preceq LI, \forall x \in \mathbb{R}^d, t \geq 0$$

定理：算法收敛性

若 m -强凸性、 L -光滑性、 n 阶轨迹正则性假设均成立，线性外推系数 $\mathbf{a}$ 满足 n 阶泰勒矩条件，且 $(\mathbf{a}, \rho, \tau)$ 满足收敛性条件： $\|\mathbf{a}\|_1 \rho^\tau < 1$ ，则算法能达到 n 阶跟踪精度。即

$$\text{ATE} := \limsup_{k \rightarrow \infty} \|x_k - x_k^*\| = \mathcal{O}(h^n)$$

收敛性条件

$$\|\mathbf{a}\|_1 \rho^\tau < 1 \iff \tau \geq \frac{\log \|\mathbf{a}\|_1}{\log(1/\rho)}$$

根据收敛性条件，可得一个“保守”的最少校正次数 $\tau_{\min}(r, n)$ （这是因为收敛性条件是一个**充分条件**），

$$\tau \geq \tau_{\min}(r, n) := \left\lceil \frac{\log \|\mathbf{a}\|_1}{\log(1/\rho)} \right\rceil.$$

在满足收敛性条件的前提下，当然希望校正次数**越少越好**，最好能让 $\tau_{\min}$ 的 $\|\mathbf{a}\|_1$ **最小**。

核心观察：当 $r > n$ 时，满足 n 阶泰勒矩条件的 $\mathbf{a}$ 有无穷组；如何寻找 $\arg \min \|\mathbf{a}\|_1$ ，进而得到 $\tau_{\min}$ ？

定义可行系数集合 $\mathcal{A}(r, n)$ 为满足 n 阶泰勒矩条件的所有 $\mathbf{a} \in \mathbb{R}^r$;


定义稀疏系数集合 $\text{SE}(r, n) := \{\mathbf{a} \in \mathcal{A}(r, n) \mid \|\mathbf{a}\|_0 = n\}$, 即其中每个系数向量的非零元素个数恰为 n 。

定理：稀疏最优性

对任意 $n \leq r$, 在所有满足 n 阶泰勒矩条件的外推系数中, ℓ_1 范数最小值总可以由某个非零元素个数恰为 n 的系数达到, 即

$$\min_{\mathbf{a} \in \mathcal{A}(r, n)} \|\mathbf{a}\|_1 = \min_{\mathbf{a} \in \text{SE}(r, n)} \|\mathbf{a}\|_1.$$

因此, 最优系数可从 $\binom{r}{n}$ 组候选支撑集中选取。



意义：从无穷多组可行系数，转化为有限组稀疏候选系数的枚举。

对于一般的 r, n , 很难给出 $\mathbf{a}^* = \arg \min_{\mathbf{a} \in \text{SE}(r, n)} \|\mathbf{a}\|_1$ 的显式形式。但当 $n = 2, 3$ 时, 可以得到简洁的闭式解。

引理: $n = 2$, 二阶精度

对任意 $r \geq 2$, 最优系数只使用两个历史点:

$$a_0 = \frac{r}{r-1}, \quad a_{r-1} = -\frac{1}{r-1}.$$

例如 $r = 3, n = 2$:

$$x_{k+1|k} = \frac{3}{2}x_k - \frac{1}{2}x_{k-2}.$$

引理: $n = 3$, 三阶精度

当 r 为奇数时^a, 最优系数使用三个历史点:

$$a_0 = \frac{r(r+1)}{(r-1)^2}, \quad a_{\frac{r-1}{2}} = -\frac{4r}{(r-1)^2}, \quad a_{r-1} = \frac{r+1}{(r-1)^2}.$$

例如 $r = 5, n = 3$:

$$x_{k+1|k} = \frac{15}{8}x_k - \frac{5}{4}x_{k-2} + \frac{3}{8}x_{k-4}.$$

^a $n = 3$ 且 r 为偶数时也有类似闭式解; 限于篇幅, 这里不展开。


当 $\mathcal{O}(h^2)$ 或 $\mathcal{O}(h^3)$ 精度已经足够时, 上述闭式系数可直接用于算法实现, 无需枚举搜索。



仿真验证——高维时变最小二乘问题

问题描述：考虑 50 维时变岭回归问题

$$f(x, t) = \frac{1}{2} \|Ax - b(t)\|^2 + \frac{\lambda}{2} \|x\|^2, \quad h = 0.01.$$



Empirical ATE ($\kappa \approx 5$)

	$\tau = 4$	$\tau = 10$
稠密四阶	DIV.	2.6×10^{-14}
稀疏四阶	3.9×10^{-12}	4.6×10^{-13}

$$\kappa \approx 5: \quad 10 \implies 4$$

$$\kappa \approx 100: \quad 150 \implies 75$$

达到 $\mathcal{O}(h^4)$ 跟踪精度的校正步数

方法： 1. 无预测 2. 稠密二阶 3. 稠密四阶 4. 稀疏四阶 ($r = 12$)

谢谢各位，请批评指正！

林仲豪 (Lin Zhonghao)

