

面向时变优化的高效预测-校正算法研究

曾宪琳

北京理工大学自动化学院

2026 年 7 月 10 日





- ① 研究背景
- ② 基本概念和研究现状
- ③ 工作内容
- ④ 创新点和展望
- ⑤ 工作总结和致谢

① 研究背景

② 基本概念和研究现状


③ 工作内容

④ 创新点和展望

⑤ 工作总结和致谢

时变优化问题


时变优化面向**目标函数**和**约束条件**随时间变化的动态系统，目标是在数据持续流入时实时跟踪最优解轨迹。



核心特点

- ① 传统优化算法（如梯度下降）通常无法实时高精度追踪最优解
- ② 计算资源有限，任务实时性高
- ③ 最优解随时间的变化趋势可预测，需要设计合适的预测器。

例 1：时变最小二乘问题（信号处理领域）



$$\begin{aligned} \mathbf{x}_t^* &= \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{C}_t \mathbf{x} - \mathbf{r}_t\|_2^2, \\ \text{s.t. } \mathbf{x} &\in \Omega(t). \end{aligned}$$

例 2：多智能体队形控制问题（控制领域）



$$\begin{aligned} \min_{p_1, \dots, p_N} \quad & \sum_{i=1}^N \|p_i - p_i^{\text{ref}}(t)\|_2^2, \\ \text{s.t. } \quad & d_{ij}^{\min}(t) \leq \|p_i - p_j\|_2 \leq d_{ij}^{\max}(t), \quad (i, j) \in \mathcal{E}(t). \end{aligned}$$

有必要在统一的时变优化视角下开展具有普适性、可扩展性的高效算法研究。

① 研究背景

② 基本概念和研究现状

③ 工作内容

④ 创新点和展望

⑤ 工作总结和致谢



时变优化（一般形式）

$$x^*(t) = \arg \min_{x \in \Omega(t)} f(x, t),$$
$$\Omega(t) := \left\{ x \mid g_i(x, t) \leq 0, i = \{1, \dots, p\}, \quad h_j(x, t) = 0, j = \{1, \dots, q\} \right\}.$$

用连续时间“优化流” (optimization flow) 描述求解过程：

$$\dot{x}(t) = \Phi(x(t), t), \quad x(0) = x_0,$$

其中 Φ 一般由梯度、二阶信息等构造，使状态 $x(t)$ 尽量贴近最优解 $x^*(t)$ ，理想情况下可**无偏跟踪**。


备注

当前时变优化研究大多假设： $f(x, t)$ 对于 x **一致强凸且光滑**，用来保证 $x^*(t)$ 轨迹的唯一性。

离散时变优化（数值计算视角）：采样时刻 $t_k = kh$, 采样周期 $0 < h \ll 1$ ，得到离散问题：

$$x_k^* := x^*(t_k) = \arg \min_{x \in \Omega_k} f_k(x, t_k),$$

数值算法在每个采样周期内迭代**有限步**，生成序列 $\{x_k\}$ 近似最优序列 $\{x_k^*\}$ 。



典型性能指标：

- 渐进跟踪误差（asymptotic tracking error, ATE）： $ATE := \limsup_{k \rightarrow \infty} \|x_k - x_k^*\|$.
- 误差阶（即跟踪精度），ATE 随 h 的标度，如 $ATE = \mathcal{O}(h)$ 、 $\mathcal{O}(h^2)$ 等，反映了算法**补偿时间变化**的能力。



时变优化中，最优解轨迹本身随时间持续移动。若每个采样时刻仅执行“就地优化”，算法序列通常会相对于最优轨迹产生滞后，因此传统优化方法在连续时变优化中，一般只能有偏跟踪；在离散时变优化中，跟踪精度一般不超过 $\mathcal{O}(h)$ 。

因此，问题应运而生：

如何达到 $\mathcal{O}(h^2)$ 以及更高阶的跟踪精度？

一种解决方案是，采用**预测—校正**框架：

预测—校正框架

- 预测阶段：利用**模型信息**（如目标函数自身的二阶信息）或**历史轨迹信息**（即算法过去迭代值），估测最优解的前向变化趋势。预测器的“设计质量”直接决定了算法的跟踪精度；
- 校正阶段：在当前时刻利用优化流或优化算法进行有限步校正，降低预测残差，增强算法收敛性。

预测-校正框架公式架构

将预测-校正框架的架构凝练如下¹:


连续时变优化中的预测-校正流:

$$\dot{x}(t) = \underbrace{\Phi_{\text{pred}}(x(t), t)}_{\text{预测}} + \underbrace{\Phi_{\text{corr}}(x(t), t)}_{\text{校正}}$$

离散时变优化中的预测-校正迭代:

预测: $x_{k+1|k} = \Phi_1(x_k, \text{模型/历史信息})$,

校正: $x_{k+1} = \Phi_2(x_{k+1|k}, f_{k+1})$.



¹Simonetto A, et al. Time-Varying Convex Optimization: Time-Structured Algorithms and Applications[J]. Proceedings of the IEEE, 2020, 108(11): 2032-2048.

连续无约束时变优化预测—校正流^a:

$$\dot{x}(t) = -\nabla_{xx}^{-1} f(x, t) \underbrace{[\nabla_{xt} f(x, t)]}_{\text{预测}} + \underbrace{\kappa \nabla_x f(x, t)}_{\text{校正}},$$

在适当正则性假设下，可实现对 $x^*(t)$ 的 渐近无偏跟踪。

离散无约束时变优化预测—校正算法^b:



预测: $x_{k+1|k} = x_k - h \nabla_{xx}^{-1} f(x_k, t_k) \nabla_{xt} f(x_k, t_k),$

多步校正: $x_{k+1} = x_{k+1|k} - \gamma \nabla_x f(x_{k+1|k}, t_{k+1}),$

在适当正则性假设下，跟踪精度可从 $\mathcal{O}(h) \rightarrow \mathcal{O}(h^2)$ 。

^aFazlyab M, et al. Prediction-Correction Interior-Point Method for Time-Varying Convex Optimization[J]. *IEEE Transactions on Automatic Control*, 2018, 63(7): 1973-1986.

^bSimonetto A, et al. A Class of Prediction-Correction Methods for Time-Varying Convex Optimization[J]. *IEEE Transactions on Signal Processing*, 2016, 64(17): 4576-4591.



连续无约束时变优化预测—校正流：

$$\dot{x}(t) = \boxed{-\nabla_{xx}^{-1} f(x, t)} \underbrace{[\nabla_{xt} f(x, t)]}_{\text{预测}} + \underbrace{\kappa \nabla_x f(x, t)}_{\text{校正}},$$

离散时变优化预测—校正算法：

$$\text{预测: } x_{k+1|k} = x_k - h \boxed{\nabla_{xx}^{-1} f(x_k, t_k)} \nabla_{xt} f(x_k, t_k),$$

$$\text{校正 (无约束): } x_{k+1} = x_{k+1|k} - \gamma \nabla_x f(x_{k+1|k}, t_{k+1}),$$

$$\text{校正 (有约束): } x_{k+1} = \mathbb{P}_{\Omega_{k+1}} [x_{k+1|k} - \gamma \nabla_x f(x_{k+1|k}, t_{k+1})].$$

总结：

- ① 现有预测—校正算法能取得较高跟踪精度。连续：渐进无偏跟踪；离散： $\mathcal{O}(h^2)$ 。
- ② 代价是极度依赖二阶信息（如 ∇_{xx}^{-1} ）和时间偏导数（如 ∇_{xt} ），计算代价高，且数值不稳定。

① 研究背景

② 基本概念和研究现状

③ 工作内容

④ 创新点和展望

⑤ 工作总结和致谢

设计目标

构建一类高跟踪精度、且无需 Hessian 求逆的预测-校正方法族，同时兼顾精度和计算代价。

① 连续无约束时变优化的 Hessian-inverse-free 预测-校正流

Lin Z, Hou J, and Zeng X. Hessian-Inverse-Free Prediction-Correction Method for Time-Varying Convex Optimization, *IEEE Conference on Decision and Control (CDC)*.

② 离散无约束时变优化的稀疏外推预测-校正算法

Lin Z, Hou J, and Zeng X. Optimal Prediction-Correction Algorithm Using Sparse Linear Extrapolation for Time-Varying Optimization, *IEEE Transactions on Signal Processing (TSP)*.

③ 带约束时变优化的原始-对偶预测-校正算法

Lin Z, Zeng X, Hou J, Sun J, Chen J. Primal-Dual Prediction-Correction Method with Tunable Memory for Linearly Constrained Time-Varying Convex Optimization, *Journal of Systems Science & Complexity (JSSC)*.



工作内容 1：连续无约束时变优化的 Hessian-inverse-free 预测—校正流

- 问题描述：

$$x^*(t) = \arg \min_{x \in \mathbb{R}^d} f(x, t),$$

其中 $f(\cdot, t)$ 对 x 二阶连续可微，并允许仅一般凸，最优解可能不唯一。

- 目标：设计 Hessian-inverse-free 的优化流 $\dot{x}(t) = \Phi(x(t), t)$ ，在不显式计算 Hessian 逆的前提下，给出强凸与一般凸情形下的收敛保证；
- 难点挑战：一般凸情形下 Hessian 可能奇异或接近奇异，经典预测—校正流中的 $\nabla_{xx}^{-1} f(x, t)$ 不再良好定义或数值不稳定。如何在不使用 $\nabla_{xx}^{-1} f(x, t)$ 的前提下设计稳定可行的流，是本部分研究的关键难点。
- 回顾经典预测—校正连续流（一般凸情况下不适用；一致强凸下无偏跟踪）

$$\dot{x}(t) = \boxed{-\nabla_{xx}^{-1} f(x, t)} \underbrace{[\nabla_{xt} f(x, t)]}_{\text{预测}} + \underbrace{\kappa \nabla_x f(x, t)}_{\text{校正}},$$

核心思路：设计辅助矩阵 $H(t)$ ，代替 $\nabla_{xx}^{-1} f(x, t)$



联合预测-校正流：

$$\begin{aligned}\dot{x}(t) &= -H(t) \left[\underbrace{\nabla_{xt}f(x,t)}_{\text{预测}} + \underbrace{\kappa \nabla_x f(x,t)}_{\text{校正}} \right], \\ \dot{H}(t) &= \underbrace{-H(t) \dot{\nabla}_{xx}f(x,t) H(t)}_{\text{预测}} + \underbrace{\alpha H(t) (\mathbf{I} - \nabla_{xx}f(x,t) H(t))}_{\text{校正}} + \underbrace{\beta H(t) (\mathbf{I} - H(t))}_{\text{锚定}}.\end{aligned}$$

其中 $\dot{\nabla}_{xx}f(x,t)$ 为 $\nabla_{xx}f(x,t)$ 沿轨迹的全导数，即 $\dot{\nabla}_{xx}f(x,t) = \sum_{i=1}^d \nabla_{xxx_i}f(x(t),t)\dot{x}_i + \nabla_{xxt}f(x(t),t)$ 。

合理选取参数 (κ, α, β) ，可得以下结论：

- ① 若 $\nabla_{xx}f(x,t) \succeq \mathbf{0}$, $\forall t \geq 0$ （一般凸），则 $\limsup_{t \rightarrow \infty} \|\nabla_x f(x,t)\|_2 = \mathcal{O}(\beta)$ ，
即梯度范数具有可调最终界；
- ② 特别地，若 $\nabla_{xx}f(x,t) \succeq m\mathbf{I} > 0$, $\forall t \geq 0$ （一致强凸），则 $\lim_{t \rightarrow \infty} \|x(t) - x^*(t)\|_2 = 0$ （无偏跟踪）。



工作内容 1：辅助矩阵流的结构和性质

$$\dot{H}(t) = \underbrace{-H(t) \dot{\nabla}_{xx} f(x, t) H(t)}_{\text{预测}} + \underbrace{\alpha H(t) (\mathbf{I} - \nabla_{xx} f(x, t) H(t))}_{\text{校正}} + \underbrace{\beta H(t) (\mathbf{I} - H(t))}_{\text{锚定}}.$$

- ① 预测项用于模拟 $\nabla_{xx}^{-1} f(x, t)$ 的变化趋势。理想情况下, $H(t) \nabla_{xx} f(x, t) = \mathbf{I}$, 因此

$$H(t) \nabla_{xx} f(x, t) = \mathbf{I} \implies \dot{H}(t) \nabla_{xx} f(x, t) + H(t) \dot{\nabla}_{xx} f(x, t) = 0 \implies \dot{H}(t) = -H(t) \dot{\nabla}_{xx} f(x, t) H(t)$$

- ② 校正项可视为一种连续时间的逆矩阵校正动力学。对非奇异矩阵 A ,

$$\dot{H} = \alpha H (I - AH)$$

其平衡点满足 $AH = I$, 即 $H = A^{-1}$ 。将 $\nabla_{xx} f(x, t)$ 代入 A 得到校正项。



工作内容 1: 辅助矩阵流的结构和性质

$$\dot{H}(t) = \underbrace{-H(t) \nabla_{xx} f(x, t) H(t)}_{\text{预测}} + \underbrace{\alpha H(t) (\mathbf{I} - \nabla_{xx} f(x, t) H(t))}_{\text{校正}} + \underbrace{\beta H(t) (\mathbf{I} - H(t))}_{\text{锚定}}.$$

- ③ 锚定项用于调节 $H(t)$ 的谱范围。该项可以抑制 $\nabla_{xx} f(x, t)$ (接近) 奇异时, $\|H(t)\|$ 过大。

H 矩阵流的良好性质

- ① 若 $H(0) \in \mathbb{S}_{++}^d$ (对称正定), 则 $H(t) \in \mathbb{S}_{++}^d, \forall t \geq 0$;
- ② 若 (α, β) 参数合适选取, 则存在 $H_1 > 0$, 使得 $\|H(t)\| \leq H_1, \forall t \geq 0$;
- ③ 若 (α, β) 参数合适选取, 则 $\limsup_{t \rightarrow \infty} \|H^{-1}(t) - \nabla_{xx} f(x, t)\| = \mathcal{O}(\beta)$ 。
特别地, 若一致强凸, 则可取 $\beta = 0$, 此时该偏差界为 0。

$H(t)$ 是 ∇_{xx}^{-1} 的一个在线替代矩阵, 在一般凸情况下仍然良好定义, 且谱界可控。



工作内容 1: Hessian-inverse-free 连续流小结

本部分核心思路

将经典预测-校正流中的显式 Hessian 逆

$$\nabla_{xx}^{-1} f(x, t)$$

替换为由辅助矩阵流在线生成的 $H(t)$ ，从而构造 Hessian-inverse-free 的联合预测-校正流。

结论与优势

- **不显式求逆：** $H(t)$ 在线生成 Hessian 逆的替代矩阵，避免直接计算 $\nabla_{xx}^{-1} f(x, t)$ ；
- **强凸情形：** 可实现对时变最优轨迹 $x^*(t)$ 的渐近无偏跟踪；
- **一般凸情形：** 即使 Hessian 奇异或病态，流仍保持良定，并可给出梯度范数的可调最终界；
- **数值实现：** 时间导数项可用有限差分近似处理；但严格离散化理论仍需进一步研究。



工作内容 2：离散无约束时变优化的稀疏外推预测-校正算法

- 问题描述：

$$x_k^* := x^*(t_k) = \arg \min_{x \in \mathbb{R}^d} f_k(x, t_k),$$

其中 $f(\cdot, t)$ 对 x 二阶连续可微、强凸，最优解序列 $\{x_k^*\}$ 唯一。

- 目标：

1. 设计一个**基于历史信息的线性外推预测-校正算法**：仅利用过去若干步的迭代点与当前梯度，在不使用二阶信息 (Hessian) 的前提下，尽可能贴近最优序列 $\{x_k^*\}$ 的变化趋势；
2. 在有限校正步数下，实现与现有 **SOTA** 预测-校正方法² (SHARP) 相当的跟踪精度。

- **难点挑战**：线性外推容易放大历史误差，若控制不当往往需要**大量校正步**才能保证效果。在不依赖二阶信息的前提下，如何在小步长 h 下兼顾**高阶精度**与**有限校正次数/较低计算开销**，是本部分的核心难题。

²Kamijima T, et al. A simple yet highly accurate prediction-correction algorithm for time-varying optimization[EB/OL]. 2025.
<https://arxiv.org/abs/2504.05798>.

工作内容 2：离散无约束时变优化的稀疏外推预测-校正算法

传统预测器结构举例：

$$x_{k+1|k} = \begin{cases} x_k \text{ (无预测)} \\ x_k - h \nabla_{xx}^{-1} f(x_k, t_k) \nabla_{xt} f(x_k, t_k) \\ x_k - h \frac{\|\nabla_t f(x_k, t_k)\| \nabla_x f(x_k, t_k)}{\|\nabla_x f(x_k, t_k)\|^2} \end{cases}$$


本课题：线性外推预测器

$$x_{k+1|k} = \sum_{i=0}^{r-1} a_i x_{k-i},$$

τ 步梯度下降校正：

$$\hat{x}_{k+1}^{(s+1)} = \hat{x}_{k+1}^{(s)} - \gamma \nabla_x f(\hat{x}_{k+1}^{(s)}, t_{k+1})$$

其中, $\hat{x}_{k+1}^{(0)} = x_{k+1|k}$, $x_{k+1} = \hat{x}_{k+1}^{(\tau)}$




分析难点：如何设计高预测精度的外推系数

$$a = [a_0, \dots, a_{r-1}]^T ?$$

工作内容 2：如何设计高预测精度的外推系数？

重要观察

若 $x^*(t)$ 局部可由次数不超过 $n-1$ 的多项式精确表示，则可用过去 r 个采样点 ($r \geq n$) 精确外推下一采样点。



关键假设： n 阶轨迹正则性是线性外推预测器达到 $\mathcal{O}(h^n)$ 精度的理论分析基础。

n 阶轨迹正则性假设

最优轨迹 $x^*(t)$ 是 $(n-1)$ 次连续可微的，且存在 $L_n > 0$ ，使得 $\|x^{*(n)}(t)\| \leq L_n, \forall t \geq 0$ 。

更一般地，若 $x^*(t)$ 具有 n 阶轨迹正则性，则希望设计 $\mathbf{a} = [a_0, \dots, a_{r-1}]^T$ ，使得

$$\left\| x^*(t_{k+1}) - \sum_{i=0}^{r-1} a_i x^*(t_{k-i}) \right\| = \mathcal{O}(h^n).$$

上式为**局部截断误差**，衡量了预测器的预测精度。



工作内容 2：高阶轨迹正则性假设是否过强？

n 阶轨迹正则性假设

最优轨迹 $x^*(t)$ 是 $(n-1)$ 次连续可微的，且存在 $L_n > 0$ ，使得 $\|x^{*(n)}(t)\| \leq L_n, \forall t \geq 0$ 。

常见误区

n 越大，假设就一定越强？

不一定。该假设只要求 $x^{*(n)}(t)$ 一致有界，并不要求所有低阶导数都一致有界。而在无穷区间 $t > 0$ 上，高阶导数有界不代表低阶导有界。

例如，对多项式轨迹而言，高阶导数反而可能更简单。因此， n 主要表示目标跟踪精度所需的最优轨迹正则性阶数。

从目标函数正则性导出：

由最优性条件 $\nabla_x f(x^*(t), t) = 0$ 可得

$$\dot{x}^*(t) = -\nabla_{xx}^{-1} f(x^*(t), t) \nabla_{xt} f(x^*(t), t).$$

- 一致强凸 + $\nabla_{xt} f$ 有界 $\Rightarrow n = 1$;
- 若进一步 $\nabla_{xxx} f, \nabla_{xxt} f, \nabla_{xtt} f$ 有界 $\Rightarrow n = 2$;
- 一般 n 需要相应更高阶偏导数。



工作内容 2：泰勒矩条件——高阶外推精度的充分条件

线性外推预测器：

$$x_{k+1|k} = \sum_{i=0}^{r-1} a_i x_{k-i}, \quad \mathbf{a} = [a_0, \dots, a_{r-1}]^\top.$$

引理：高阶预测精度

若 $x^*(t)$ 满足 n 阶轨迹正则性，且 $\mathbf{a}$ 满足 n 阶泰勒矩条件，则

$$\left\| x^*(t_{k+1}) - \sum_{i=0}^{r-1} a_i x^*(t_{k-i}) \right\| = \mathcal{O}(h^n).$$

进一步，结合线性外推预测器形式，可得

$$\left\| x_{k+1|k} - x^*(t_{k+1}) - \sum_{i=0}^{r-1} a_i (x_{k-i} - x^*(t_{k-i})) \right\| = \mathcal{O}(h^n).$$

n 阶泰勒矩条件（充分条件）

$$\sum_{i=0}^{r-1} (i+1)^j a_i = \begin{cases} 1, & j = 0, \\ 0, & j = 1, \dots, n-1. \end{cases}$$

SHARP 论文中出现的一组特例：

$$a_i = (-1)^i \binom{n}{i+1}, \quad i = 0, 1, \dots, n-1.$$

问：满足 n 阶泰勒矩条件的外推系数 $\mathbf{a}$ 是否唯一？ 答： $r = n$ ，唯一（即上面特例）； $r > n$ ，无穷组。



工作内容 2: 收敛性条件

将线性外推预测器的输出 $x_{k+1|k}$ 作为校正环节输入, 进行 τ 步梯度下降校正:

$$\hat{x}_{k+1}^{(0)} = x_{k+1|k} \xrightarrow{\text{输入}} \boxed{\hat{x}_{k+1}^{(s+1)} = \hat{x}_{k+1}^{(s)} - \gamma \nabla_x f(\hat{x}_{k+1}^{(s)}, t_{k+1})} \xrightarrow{\text{输出}} x_{k+1} = \hat{x}_{k+1}^{(\tau)}$$

在一致 m -强凸性与 L -光滑性假设下, τ 步校正后,

$$\|x_{k+1} - x_{k+1}^*\| \leq \rho^\tau \|x_{k+1|k} - x_{k+1}^*\|,$$

其中 $\rho = \max\{|1 - \gamma m|, |1 - \gamma L|\} < 1$.

一致 m -强凸性与 L -光滑性假设

存在常数 $0 < m \leq L$, 使得

$$mI \preceq \nabla_{xx} f(x, t) \preceq LI, \forall x \in \mathbb{R}^d, t \geq 0$$

定理: 算法收敛性

若 m -强凸性、 L -光滑性、 n 阶轨迹正则性假设均成立, 线性外推系数 $\mathbf{a}$ 满足 n 阶泰勒矩条件, 且 $(\mathbf{a}, \rho, \tau)$ 满足收敛性条件: $\|\mathbf{a}\|_1 \rho^\tau < 1$, 则算法能达到 n 阶跟踪精度。即

$$\text{ATE} := \limsup_{k \rightarrow \infty} \|x_k - x_k^*\| = \mathcal{O}(h^n)$$



工作内容 2：稀疏系数设计

收敛性条件

$$\|\mathbf{a}\|_1 \rho^\tau < 1 \iff \tau \geq \frac{\log \|\mathbf{a}\|_1}{\log(1/\rho)}$$

根据收敛性条件，可得一个“保守”的最少校正次数 $\tau_{\min}(r, n)$ （这是因为收敛性条件是一个**充分条件**），

$$\tau \geq \tau_{\min}(r, n) := \left\lceil \frac{\log \|\mathbf{a}\|_1}{\log(1/\rho)} \right\rceil.$$

在满足收敛性条件的前提下，当然希望校正次数**越少越好**，最好能让 $\tau_{\min}$ 的 $\|\mathbf{a}\|_1$ **最小**。

核心观察：当 $r > n$ 时，满足 n 阶泰勒矩条件的 $\mathbf{a}$ 有无穷组；如何寻找 $\arg \min \|\mathbf{a}\|_1$ ，进而得到 $\tau_{\min}$ ？



工作内容 2：稀疏系数设计

定义可行系数集合 $\mathcal{A}(r, n)$ 为满足 n 阶泰勒矩条件的所有 $\mathbf{a} \in \mathbb{R}^r$;

定义稀疏系数集合 $\text{SE}(r, n) := \{\mathbf{a} \in \mathcal{A}(r, n) \mid \|\mathbf{a}\|_0 = n\}$, 即其中每个系数向量的非零元素个数**恰为** n 。

定理：稀疏最优性

对任意 $n \leq r$, 在所有满足 n 阶泰勒矩条件的外推系数中, ℓ_1 范数最小值总可以由某个非零元素个数恰为 n 的系数达到, 即

$$\min_{\mathbf{a} \in \mathcal{A}(r, n)} \|\mathbf{a}\|_1 = \min_{\mathbf{a} \in \text{SE}(r, n)} \|\mathbf{a}\|_1.$$

因此, 最优系数可从 $\binom{r}{n}$ 组候选支撑集中选取。

n 阶泰勒矩条件

$$\sum_{i=0}^{r-1} (i+1)^j a_i = \begin{cases} 1, & j = 0, \\ 0, & j = 1, \dots, n-1. \end{cases}$$

当 $r > n$ 时, $\mathcal{A}(r, n)$ 中包含无穷多组系数; 定理说明, 只需在 $\text{SE}(r, n)$ 中枚举有限组候选系数。

意义：从无穷多组可行系数，转化为有限组稀疏候选系数的枚举。



工作内容 2：低阶显式系数

对于一般的 r, n ，很难给出 $\mathbf{a}^* = \arg \min_{\mathbf{a} \in \text{SE}(r, n)} \|\mathbf{a}\|_1$ 的显式形式。但当 $n = 2, 3$ 时，可以得到简洁的闭式解。

引理： $n = 2$ ，二阶精度

对任意 $r \geq 2$ ，最优系数只使用两个历史点：

$$a_0 = \frac{r}{r-1}, \quad a_{r-1} = -\frac{1}{r-1}.$$

例如 $r = 3, n = 2$ ：

$$x_{k+1|k} = \frac{3}{2}x_k - \frac{1}{2}x_{k-2}.$$

引理： $n = 3$ ，三阶精度

当 r 为奇数时^a，最优系数使用三个历史点：

$$a_0 = \frac{r(r+1)}{(r-1)^2}, \quad a_{\frac{r-1}{2}} = -\frac{4r}{(r-1)^2}, \quad a_{r-1} = \frac{r+1}{(r-1)^2}.$$

例如 $r = 5, n = 3$ ：

$$x_{k+1|k} = \frac{15}{8}x_k - \frac{5}{4}x_{k-2} + \frac{3}{8}x_{k-4}.$$

^a $n = 3$ 且 r 为偶数时也有类似闭式解；限于篇幅，这里不展开。


当 $\mathcal{O}(h^2)$ 或 $\mathcal{O}(h^3)$ 精度已经足够时，上述闭式系数可直接用于算法实现，无需枚举搜索。

工作内容 2：仿真验证——标量时变优化问题

问题描述：考虑标量时变优化问题 $f(x, t) = \frac{1}{2} (x - \cos(\omega t))^2 + \lambda \log(1 + e^{\mu x})$ ，采样周期 $h = 0.01$ 。

方法说明：

- ① TVGD：无预测器；
- ② GTT：传统预测-校正方法，使用 Hessian 和时间偏导数；
- ③ SPC：两点外推方法， $r = n = 2$ ；
- ④ SHARP：满窗口外推方法， $r = n = 3$ ；
- ⑤ SE-PC：稀疏外推方法， $r = 5, n = 3$ 。




现象： 1. TVGD、SPC/GTT、SHARP(3)/SE-PC 分别对应 $O(h)$ 、 $O(h^2)$ 、 $O(h^3)$ 跟踪精度；
2. 在较少校正步数下，SE-PC($\tau_{\min} = 3$) 比 SHARP(3)($\tau_{\min} = 7$) 更稳定地达到三阶精度。

工作内容 2：仿真验证——高维时变最小二乘问题

问题描述：考虑 50 维时变岭回归问题 $f(x, t) = \frac{1}{2} \|Ax - b(t)\|^2 + \frac{\lambda}{2} \|x\|^2$ ，采样周期 $h = 0.01$ 。

方法说明：

- TVGD：无预测器；
- SPC：两点外推方法， $r = n = 2$ ；
- SHARP(4)：满窗口四阶外推方法， $r = n = 4$ ；
- SE-PC：本文方法，采用 SE(12, 4) 中的 ℓ_1 最优稀疏系数。



- 现象：**
1. TVGD、SPC、SHARP(4)/SE-PC 分别对应 $O(h)$ 、 $O(h^2)$ 、 $O(h^4)$ 跟踪精度；
 2. 在较少校正步数下，SE-PC($\tau_{\min} = 4$) 比 SHARP(4)($\tau_{\min} = 10$) 更稳定地达到四阶精度。



工作内容 3：线性等式约束下的原始-对偶跟踪问题

- **问题描述：**考虑线性等式约束时变优化问题

$$x_k^* = \arg \min_{x \in \mathbb{R}^d} f_k(x), \quad \text{s.t.} \quad A_k x = b_k,$$

采样时刻 $t_k = kh$, 其中 $f_k(x) = f(x, t_k)$, $A_k = A(t_k)$, $b_k = b(t_k)$ 。

- **原始-对偶解：**令 $z_k^* = [(x_k^*)^\top, (\lambda_k^*)^\top]^\top$, 其满足 t_k 时刻的 KKT 条件, 即

$$\nabla f_k(x_k^*) + A_k^\top \lambda_k^* = 0, \quad A_k x_k^* = b_k.$$

- **目标：**在不使用 Hessian 和高阶时间导数的前提下, 设计一类离散原始-对偶预测-校正算法, 用有限步校正同时跟踪原始变量序列 $\{x_k^*\}$ 与相应的对偶变量序列 $\{\lambda_k^*\}$ 。
- **研究动机：**即便在线性等式约束时变优化这一子类问题上, 关于高精度、低计算开销的原始-对偶预测-校正方法仍相对不足。

工作内容 3：原始-对偶预测-校正算法设计

聚合变量：令 $z_k = [x_k^\top, \lambda_k^\top]^\top$

线性外推预测：

$$z_{k+1|k} = \sum_{i=0}^{r-1} a_i z_{k-i}, \quad z_{k+1|k} = \begin{bmatrix} x_{k+1|k} \\ \lambda_{k+1|k} \end{bmatrix}.$$


τ 步原始-对偶校正：

$$\hat{x}_{k+1}^{(s+1)} = \hat{x}_{k+1}^{(s)} - \eta_x \underbrace{\left[\nabla f_{k+1}(\hat{x}_{k+1}^{(s)}) + A_{k+1}^\top \hat{\lambda}_{k+1}^{(s)} \right]}_{\text{原始变量梯度下降}},$$

$$\hat{\lambda}_{k+1}^{(s+1)} = \hat{\lambda}_{k+1}^{(s)} + \eta_\lambda \underbrace{\left[A_{k+1} \hat{x}_{k+1}^{(s+1)} - b_{k+1} \right]}_{\text{对偶变量梯度上升}}.$$

其中 $\hat{x}_{k+1}^{(0)} = x_{k+1|k}$, $\hat{\lambda}_{k+1}^{(0)} = \lambda_{k+1|k}$,
最终取 $x_{k+1} = \hat{x}_{k+1}^{(\tau)}$, $\lambda_{k+1} = \hat{\lambda}_{k+1}^{(\tau)}$ 。

带约束的预测-校正算法流程图：



本例中的拉格朗日函数：

$$L_{k+1}(x, \lambda) = f_{k+1}(x) + \lambda^\top (A_{k+1}x - b_{k+1})$$



工作内容 3：原始-对偶预测-校正算法收敛性

定理：算法收敛性

在右侧假设以及 n 阶轨迹正则性假设成立下，若 $\mathbf{a}$ 满足 n 阶泰勒矩条件，步长 η_x, η_λ 合适选取，且满足收敛性条件

$$\rho_{\text{pd}}^\tau \cdot \frac{\max\{c_x, c_\lambda\}}{\min\{c_x, c_\lambda\}} \cdot \|\mathbf{a}\|_1^2 < 1$$

则原始-对偶预测-校正算法可实现 n 阶跟踪精度：

$$\limsup_{k \rightarrow \infty} \|z_k - z_k^*\| = \mathcal{O}(h^n).$$

其中 $c_x := 1 - \eta_x \eta_\lambda \underline{\sigma}^2$, $c_\lambda := \frac{\eta_x}{\eta_\lambda}$, $\rho_{\text{pd}} := \max\{1 - \eta_x m(1 - \eta_x L), 1 - \eta_x \eta_\lambda \underline{\sigma}^2\} \in (0, 1)$ 。

线性外推框架可从无约束情形自然推广到原始-对偶约束情形，其核心仍是通过减小 $\|\mathbf{a}\|_1$ 降低校正开销。

一致 m -强凸性与 L -光滑性假设

存在常数 $0 < m \leq L$ ，使得

$$mI \preceq \nabla_{xx} f(x, t) \preceq LI, \forall x \in \mathbb{R}^d, t \geq 0$$

约束矩阵正则性

A_k 行满秩，且其非零奇异值一致有界：

$$\sigma_{\min}^+(A_k) \geq \underline{\sigma} > 0, \quad \|A_k\| \leq \bar{\sigma}.$$

① 研究背景

② 基本概念和研究现状

③ 工作内容

④ 创新点和展望

⑤ 工作总结和致谢

本工作的研究创新可概括如下：

- ① **整体框架**：面向时变优化构建一套兼顾连续流与离散算法的以降低 Hessian 求逆依赖为核心的预测-校正方法族；
- ② **连续流**：构建将**辅助矩阵流**嵌入优化流的连续预测-校正模型，在避免显式 Hessian 求逆的同时，给出强凸与一般凸情形下的收敛保证；
- ③ **离散算法**：提出基于**稀疏线性外推**的预测结构，在保持高阶跟踪精度的同时降低校正开销；
- ④ **约束拓展**：在线性等式约束时变优化中构造**原始-对偶预测-校正算法**，验证线性外推框架在约束场景下的适用性。

未来展望：

- ① 进一步研究完全 **Hessian-free** 的连续预测-校正流，减少对 Hessian 信息本身的依赖；
- ② 将稀疏线性外推预测方法推广到更一般的约束形式，如非线性约束、不等式约束与分布式约束场景。

① 研究背景

② 基本概念和研究现状

③ 工作内容

④ 创新点和展望

⑤ 工作总结和致谢



目前关于时变优化的工作成果总结如下：

- ① Lin Z, Hou J, and **Zeng X**. Hessian-Inverse-Free Prediction-Correction Method for Time-Varying Convex Optimization, under review, *IEEE Conference on Decision and Control*.
- ② Lin Z, Hou J, and **Zeng X**. Optimal Prediction-Correction Algorithm Using Sparse Linear Extrapolation for Time-Varying Optimization, *IEEE Transactions on Signal Processing*, vol. 74, pp. 2564–2578, 2026.
- ③ Lin Z, **Zeng X**, Hou J, Sun J, Chen J. Primal-Dual Prediction-Correction Method with Tunable Memory for Linearly Constrained Time-Varying Convex Optimization, *Journal of Systems Science and Complexity*, vol. 39, no. 2, pp. 483–510, 2026.

感谢合作者陈杰教授、孙健教授、侯洁老师和林仲豪同学在研究工作中的努力和支持。

谢谢各位，请批评指正！

